

Улучшение activation steering с помощью обучаемого восстановления скрытых представлений

Исследовательский отчёт по задаче interpretability

Автор: Иван Орехов

23 августа 2026 г.

Аннотация

В работе исследуется задача улучшения activation steering в языковой модели GPT-2 Small. Стандартная steering-интервенция имеет вид

$$\tilde{h} = h + \alpha v,$$

где h — промежуточное скрытое представление модели, v — направление, соответствующее целевому семантическому концепту, а α — сила steering. Увеличение α позволяет усилить выраженность нужного концепта, однако при достаточно больших значениях скрытые состояния модели уходят из области естественных активаций, что приводит к росту perplexity и деградации генерации.

Цель работы — проверить, можно ли обучить небольшой repair/denoising-модуль, который будет частично восстанавливать скрытое состояние после steering, сохраняя при этом семантический эффект интервенции.

В качестве steering-направления используется decoder-вектор Sparse Autoencoder (SAE) на седьмом transformer-блоке GPT-2. Основной выбранный признак имеет индекс 17363 и хорошо отделяет science-тексты от контрольных примеров. В работе последовательно исследуются: raw steering baseline, same-layer Gaussian MSE denoiser, downstream gated Gaussian repair, а также improved interpolation denoiser с corruption

$$x_t = th + (1 - t)\epsilon.$$

Содержание

1	Постановка задачи	3
2	Используемая модель и инструменты	3
2.1	GPT-2 Small	3
2.2	Sparse Autoencoder	4
3	Поиск и валидация steering-признака	4
3.1	Идея отбора	4
3.2	Результаты поиска	4
4	Метрики качества	5
4.1	Concept score	5
4.2	Completion-only perplexity	5
4.3	Repetition metrics	5
4.4	Generation protocol	5
5	Эксперимент 1: raw steering	6

6 Эксперимент 2: same-layer Gaussian denoiser	7
6.1 Обучающая постановка	7
6.2 Reconstruction validation	7
6.3 Тест на реальном steering	8
7 Эксперимент 3: downstream gated Gaussian repair	9
7.1 Мотивация	9
7.2 Архитектура	9
7.3 Loss	9
7.4 Training validation	10
7.5 Steering test	10
8 Эксперимент 4: improved interpolation denoiser	11
8.1 Новая схема corruption	11
8.2 Reconstruction validation	12
8.3 Отображение $\alpha \rightarrow t$	12
8.4 Steering results	13
9 Обсуждение результатов	14
9.1 Почему хороший reconstruction MSE не гарантирует хороший steering	14
9.2 Почему downstream LM repair оказался слишком сильным	14
9.3 Почему interpolation scheme оказалась лучше	14
10 Ограничения экспериментов	15
11 Возможные дальнейшие эксперименты	15
12 Заключение	16

1. Постановка задачи

Activation steering — это способ управлять поведением языковой модели без изменения её весов. Пусть

$$\mathbf{h} \in \mathbb{R}^d$$

— скрытое представление на некотором промежуточном слое, а

$$\mathbf{v} \in \mathbb{R}^d$$

— направление в пространстве активаций, связанное с определённым семантическим концептом. Тогда стандартная интервенция записывается как

$$\tilde{\mathbf{h}} = \mathbf{h} + \alpha \mathbf{v}. \quad (1)$$

Параметр α определяет силу steering.

В идеальном случае увеличение α должно усиливать нужный концепт, не ухудшая качество текста. На практике это выполняется только до определённого значения α . При больших интервенциях скрытое состояние становится нехарактерным для исходной модели, вследствие чего могут возникать рост perplexity, потеря семантической связности, повторения, деградация грамматики, исчезновение самого целевого концепта при слишком сильной интервенции.

Таким образом, задача состоит не просто в максимизации concept score, а в улучшении совместного компромисса

$$\text{concept score} \uparrow, \quad \text{PPL} \downarrow.$$

Основная идея работы: после вмешательства

$$\mathbf{h} \mapsto \mathbf{h} + \alpha \mathbf{v}$$

применить обучаемый модуль восстановления

$$D_\theta$$

и проверить, способен ли он вернуть скрытое представление ближе к естественной области активаций модели, не удалив при этом полезный семантический компонент.

2. Используемая модель и инструменты

2.1. GPT-2 Small

Во всех экспериментах используется GPT-2 Small. Модель содержит 12 transformer-блоков. Размерность residual stream:

$$d_{\text{model}} = 768.$$

Для доступа к промежуточным активациям используется библиотека TransformerLens. Основной steering выполняется в точке

$$\text{blocks.6.hook_resid_pre},$$

что соответствует входу в седьмой transformer-блок при обычной нумерации слоёв с единицы.

2.2. Sparse Autoencoder

Для получения интерпретируемого steering-направления используется Sparse Autoencoder. Пусть

$$W_{\text{dec}} \in \mathbb{R}^{d_{\text{SAE}} \times 768}$$

— матрица decoder-векторов SAE. Для признака с индексом j steering direction определяется как

$$v = W_{\text{dec}}[j]. \quad (2)$$

Таким образом, SAE одновременно используется:

1. для поиска концептуально осмысленного направления;
2. для количественной оценки того, насколько сгенерированный текст выражает целевой концепт.

3. Поиск и валидация steering-признака

3.1. Идея отбора

Для поиска подходящего SAE-признака использовались две группы текстов science-тексты и контрольные тексты, не относящиеся к science-концепту.

Для каждого текста вычислялись residual stream активации седьмого блока, после чего они кодировались SAE. Для признака j score текста задавался как

$$s_j(x) = \max_t z_{t,j}, \quad (3)$$

где $z_{t,j}$ — SAE activation признака j на токене t .

Хороший кандидат должен одновременно иметь высокую среднюю активацию на science-текстах, низкую активацию на control-текстах, высокий science active rate, низкий control active rate.

3.2. Результаты поиска

Наиболее сильным оказался feature 17363.

Таблица 1: Held-out validation лучших SAE-признаков.

Feature	Science mean	Control mean	Science active	Control active
17363	8.2169	0.0000	1.0	0.0
9695	5.2055	0.0000	0.6	0.0
2513	7.0168	0.0837	0.9	0.1
6194	3.7151	0.0000	0.7	0.0
20063	2.0430	0.0000	0.6	0.0

Для feature 17363:

$$\text{science mean} = 8.2169,$$

$$\text{control mean} = 0,$$

$$P(\text{active} \mid \text{science}) = 1,$$

$$P(\text{active} \mid \text{control}) = 0.$$

Следовательно, feature 17363 имеет наиболее чистое разделение и используется далее как целевое steering-направление:

$$j = 17363.$$

Норма decoder-вектора:

$$\|\mathbf{v}\|_2 \approx 1.00004.$$

Поэтому

$$\|\alpha \mathbf{v}\|_2 \approx |\alpha|,$$

что делает коэффициент α удобной непосредственной мерой силы perturbation.

4. Метрики качества

4.1. Concept score

После генерации каждый текст повторно прогоняется через *чистую* GPT-2, то есть без steering и без repair. Затем на седьмом блоке вычисляются SAE activations.

Concept score:

$$C(x) = \max_t z_{t,17363}. \quad (4)$$

Это важно чтобы измерять не искусственную активацию feature непосредственно во время steering, а измерять то, насколько итоговый сгенерированный текст сам по себе активирует нужный SAE feature.

4.2. Completion-only perplexity

Качество текста оценивается clean GPT-2. Используется только continuation, без prompt-токенов:

$$\text{PPL} = \exp \left(-\frac{1}{N} \sum_{i=1}^N \log p(x_i \mid x_{<i}) \right). \quad (5)$$

Чем меньше PPL, тем более естественным для GPT-2 является generated text.

4.3. Repetition metrics

Дополнительно вычислялись

$$\text{dist}_n = \frac{\#\{\text{уникальные } n\text{-граммы}\}}{\#\{\text{все } n\text{-граммы}\}},$$

и

$$\text{rep}_3 = 1 - \text{dist}_3.$$

4.4. Generation protocol

Для steering evaluation использовались:

- 6 нейтральных prompt-шаблонов;
- 5 random seeds;
- 50 новых токенов;
- temperature = 0.8;
- top- p = 0.95.

5. Эксперимент 1: raw steering

Сначала исследовалась стандартная интервенция

$$\tilde{h} = h + \alpha v$$

без repair-модуля.

Таблица 2: Raw steering baseline на седьмом блоке.

α	Concept	PPL	Dist-3	Rep-3
0	3.2108	11.4722	0.9877	0.0123
4	3.7994	11.4190	0.9681	0.0319
8	4.7941	11.4439	0.9771	0.0229
16	7.1939	14.4280	0.9796	0.0204
32	7.7055	26.5748	0.9915	0.0085
64	0.0000	235.8455	0.9577	0.0423
96	0.0000	2890.6787	0.9567	0.0433
128	0.0000	19909.8083	0.9843	0.0157

Из таблицы видно несколько режимов.

При $\alpha = 4$ и $\alpha = 8$ concept score увеличивается практически без роста perplexity.

При $\alpha = 16$:

$$C : 3.2108 \rightarrow 7.1939,$$

$$\text{PPL} : 11.4722 \rightarrow 14.4280.$$

Concept резко усиливается, а PPL растёт умеренно.

При $\alpha = 32$:


$$C = 7.7055, \quad \text{PPL} = 26.5748.$$

Concept всё ещё высок, но качество уже заметно ухудшается.


При $\alpha \geq 64$ возникает коллапс: целевой feature перестаёт проявляться, а PPL становится очень большим.

Следовательно, главный полезный диапазон:

$$8 \lesssim \alpha \lesssim 32.$$



(a) Concept score



(b) Completion PPL

6. Эксперимент 2: same-layer Gaussian denoiser

6.1. Обучающая постановка

Для чистой активации $\mathbf{h}$ генерируется

$$\epsilon \sim \mathcal{N}(0, \sigma^2 I),$$

после чего

$$x = \mathbf{h} + \epsilon.$$

Шум параметризуется через ожидаемую норму perturbation r :

$$\sigma = \frac{r}{\sqrt{768}},$$

причём

$$r \in [4, 128]$$

выбирается log-uniformly.

Denoiser имеет residual-форму:

$$D_\theta(x, \sigma) = x + \Delta_\theta(x, \sigma).$$

Параметр σ кодируется 64-мерным sinusoidal embedding. Архитектура:

$$(768 + 64) \rightarrow 1536 \rightarrow 1536 \rightarrow 768.$$

Последний correction-layer инициализируется нулями, поэтому в начале обучения denoiser близок к identity.

Loss:

$$\mathcal{L}_{\text{MSE}} = \mathbb{E} [\|D_\theta(\mathbf{h} + \epsilon, \sigma) - \mathbf{h}\|_2^2]. \quad (6)$$

Target steering-vector $\mathbf{v}$ во время обучения **не используется**. Это важно для честного теста generalization.

6.2. Reconstruction validation

Таблица 3: Reconstruction MSE Gaussian denoiser.

r	Raw MSE	Denoised MSE	Improvement
4	0.0209	0.0372	0.562×
8	0.0834	0.0920	0.906×
16	0.3335	0.3536	0.943×
32	1.3269	1.2710	1.044×
64	5.3347	4.1166	1.296×
96	12.0122	8.2564	1.455×
128	21.2885	13.6826	1.556×

Модель лучше всего восстанавливает сильный random noise, но в малом noise regime $r = 4, 8, 16$ reconstruction даже немного ухудшается.




Рис. 2: Отношение raw MSE к denoised MSE для Gaussian baseline.

6.3. Тест на реальном steering

На inference сначала выполняется

$$\mathbf{h} \mapsto \mathbf{h} + \alpha \mathbf{v},$$

а затем denoiser применяется на том же седьмом слое.

Таблица 4: Raw steering и same-layer Gaussian denoising.


α	C_{raw}	C_{den}	PPL raw	PPL den
0	3.2108	3.2108	11.4722	11.4722
4	3.7994	4.0031	11.4190	11.4483
8	4.7941	4.5073	11.4439	11.5170
16	7.1939	7.2884	14.4280	14.3966
24	7.5621	7.2755	22.2017	21.9725
32	7.7055	5.9889	26.5748	73.8180
40	6.5409	2.0590	88.7531	526.3774
48	1.1882	0.0665	521.9011	2334.6003
64	0.0000	0.0000	235.8455	4243.6448

При $\alpha = 16$ есть небольшой matched-alpha выигрыш:


$$C : 7.1939 \rightarrow 7.2884,$$

$$\text{PPL} : 14.4280 \rightarrow 14.3966.$$

Однако начиная с $\alpha = 32$ denoiser резко ухудшает ситуацию. Следовательно, обычная MSE-реконструкция random Gaussian noise не обеспечивает устойчивого улучшения steering. Это понятная ситуация, ведь в лучшем случае модель была обучена восстанавливать текущий слой к прежнему состоянию без шума, а не убирает появившийся шум в последующий слоях, который возможно и ломает генерацию.



(a) Concept



(b) PPL

7. Эксперимент 3: downstream gated Gaussian repair

7.1. Мотивация

Same-layer MSE denoiser обучается напрямую приближать modified activation к clean activation. Но в таком случае существует риск удалить и сам полезный steering-компонент.

Поэтому был исследован другой подход corruption вносится на 7-м блоке, repair применяется позже, на 9-м блоке.

Используются:

`blocks.6.hook_resid_pre`

для perturbation и

`blocks.8.hook_resid_pre`

для repair.

7.2. Архитектура

Training corruption:

$$\mathbf{h}_7^{\text{noisy}} = \mathbf{h}_7 + \epsilon.$$

На 9-м блоке используется gated bottleneck:

$$z = E_{\theta}([x, \text{emb}(\sigma)]),$$

где

$$(768 + 64) \rightarrow 1024 \rightarrow 256.$$

Из z вычисляются correction и gate:

$$\Delta h = H_{\text{corr}}(z),$$

$$g = \text{sigmoid}(H_{\text{gate}}(z)),$$

$$R_{\theta}(x, \sigma) = x + g\Delta h.$$

7.3. Loss

Используется LM objective:

$$\mathcal{L} = \mathcal{L}_{\text{LM}} + 10^{-3}\mathcal{L}_{\text{corr}} + 0.5\mathcal{L}_{\text{preserve}}.$$

Вводятся

$$d_{\text{raw}} = h_9^{\text{raw}} - h_9^{\text{clean}},$$

$$d_{\text{rep}} = h_9^{\text{repaired}} - h_9^{\text{clean}}.$$

Коэффициент сохранённой проекции:

$$\rho = \frac{\langle d_{\text{rep}}, d_{\text{raw}} \rangle}{\|d_{\text{raw}}\|_2^2}.$$

Preservation penalty:

$$\mathcal{L}_{\text{preserve}} = \max(0, 0.5 - \rho)^2.$$

7.4. Training validation

После обучения:

$$\text{PPL}_{\text{clean}} = 50.1114,$$

$$\text{PPL}_{\text{raw noisy}} = 90.4511,$$


$$\text{PPL}_{\text{repaired}} = 47.4812.$$

Также:


$$\bar{g} = 0.9062,$$

$$\rho = 0.9830.$$

На random Gaussian validation repair выглядит очень сильным. Однако PPL ниже clean PPL уже показывает, что сеть, вероятно, делает не только локальное восстановление, а более общий residual rewrite.



(a) Training loss



(b) Validation PPL

Рис. 4: Обучение downstream gated repair.

7.5. Steering test

Таблица 5: Downstream gated repair на target steering.

α	C_{raw}	C_{rep}	PPL raw	PPL rep	$\ \Delta h\ $
4	3.7994	2.2744	11.4190	22.5930	34.33
8	4.7941	3.0913	11.4439	22.9201	33.05
16	7.1939	4.6080	14.4280	21.9860	32.42
24	7.5621	5.2496	22.2017	27.3693	34.19
32	7.7055	4.6959	26.5748	44.2995	36.85
40	6.5409	1.2408	88.7531	117.5343	41.16
48	1.1882	0.2271	521.9011	360.8565	43.85
64	0.0000	0.0000	235.8455	140.4618	61.77

В рабочем диапазоне $\alpha = 4 \dots 32$ модель одновременно уменьшает concept и повышает PPL. Положительное восстановление PPL возникает только в режиме уже почти полного concept collapse.




Рис. 5: Диагностика gated repair.

Ключевой failure mode — слишком большая correction. Уже при $\alpha = 4$

$$\|\Delta h\| \approx 34.3,$$

что во много раз больше самой steering perturbation.

Высокое ρ не спасает ситуацию, поскольку оно контролирует только проекцию вдоль d_{raw} . Ортогональная компонента может оставаться огромной:

$$d_{\text{rep}} = 0.983 d_{\text{raw}} + d_{\perp}.$$

8. Эксперимент 4: improved interpolation denoiser

8.1. Новая схема corruption

Вместо additive Gaussian noise рассматривается

$$x_t = t\mathbf{h} + (1 - t)\epsilon, \quad \epsilon \sim \mathcal{N}(0, I). \quad (7)$$

Первая версия interpolation denoiser оказалась нестабильной около $t \rightarrow 1$: сеть могла вносить большую correction даже при почти чистом input.

Поэтому были сделаны два изменения.

Первое:

$$t \sim U[0.5, 1].$$

Второе — архитектурное ограничение:

$$D_{\theta}(x_t, t) = x_t + (1 - t)\Delta_{\theta}(x_t, t). \quad (8)$$

Теперь при $t = 1$:

$$D_{\theta}(\mathbf{h}, 1) = \mathbf{h}$$

точно по построению.

Архитектура:

$$(768 + 64) \rightarrow 1536 \rightarrow 1536 \rightarrow 768.$$

Loss:

$$\mathcal{L}_{\text{interp}} = \mathbb{E} \|D_{\theta}(x_t, t) - \mathbf{h}\|_2^2.$$

8.2. Reconstruction validation

Таблица 6: Improved interpolation denoiser: reconstruction validation.

t	Raw MSE	Denoised MSE	Improvement
0.99	0.010214	0.002717	$3.759\times$
0.95	0.255346	0.054729	$4.666\times$
0.90	1.021360	0.163536	$6.245\times$
0.80	4.084947	0.389751	$10.481\times$
0.70	9.190544	0.586672	$15.666\times$
0.60	16.341894	1.118401	$14.612\times$
0.50	25.532839	2.787411	$9.160\times$

Это значительно лучше предыдущих reconstruction results: improvement больше 1 во всём рассматриваемом диапазоне.

Особенно важно, что при $t = 0.99$ и 0.95 denoiser также улучшает reconstruction, то есть архитектура перестала разрушать почти clean states.

8.3. Отображение $\alpha \rightarrow t$

Training corruption (7) и реальный steering

$$\mathbf{h} + \alpha \mathbf{v}$$

не являются эквивалентными.

Поэтому используется fixed scale-matching heuristic:

$$q = \frac{|\alpha| \|\mathbf{v}\|_2}{\mathbb{E} \|\mathbf{h}_7\|_2}, \quad (9)$$

$$t_{\alpha} = \frac{1}{1 + q}. \quad (10)$$

Значение затем ограничивается training range.




Рис. 6: Fixed scale-matching $\alpha \rightarrow t$.

8.4. Steering results

Таблица 7: Improved interpolation denoiser: steering test.

α	t_α	C_{raw}	C_{den}	PPL raw	PPL den
0	1.0000	3.2108	3.2108	11.4722	11.4722
4	0.9623	3.7994	3.6714	11.4190	12.2598
8	0.9274	4.7941	4.8772	11.4439	12.3010
16	0.8645	7.1939	7.9059	14.4280	16.9570
24	0.8097	7.5621	8.2392	22.2017	21.4873
32	0.7614	7.7055	9.0681	26.5748	50.7937
40	0.7186	6.5409	5.2930	88.7531	84.6016
48	0.6803	1.1882	0.8866	521.9011	502.0176
64	0.6147	0.0000	0.0000	235.8455	2330.0457

Наиболее важный результат:

$$\alpha = 24.$$

В этой точке:

$$C : 7.5621 \rightarrow 8.2392,$$

то есть concept score увеличивается примерно на 9%.

Одновременно:

$$\text{PPL} : 22.2017 \rightarrow 21.4873.$$

Следовательно, denoised point строго лучше raw point по обоим главным метрикам. Это локальное Pareto dominance.

При $\alpha = 16$ и $\alpha = 32$ denoiser ещё сильнее повышает concept:

$$7.1939 \rightarrow 7.9059,$$

$$7.7055 \rightarrow 9.0681,$$

но PPL также увеличивается.

При $\alpha = 40$ PPL немного уменьшается:


$$88.7531 \rightarrow 84.6016,$$

но concept падает:


$$6.5409 \rightarrow 5.2930.$$

При $\alpha = 64$ наблюдается новый collapse:

$$\text{PPL} : 235.8455 \rightarrow 2330.0457.$$



(a) Concept



(b) PPL

9. результатов

9.1. Почему хороший reconstruction MSE не гарантирует хороший steering

Ключевой вывод серии экспериментов: малый reconstruction error на искусственном noise distribution не является достаточным условием успешного steering repair.

Gaussian noise:

$$\epsilon \sim \mathcal{N}(0, \sigma^2 I)$$

изотропен и не имеет специальной семантической структуры.

Steering perturbation:

$$\delta h_{\text{steer}} = \alpha v$$

наоборот, полностью направлен вдоль конкретного SAE decoder-vector.

Поэтому обучающая и тестовая геометрии perturbation существенно различаются. Вследствие чего было предложено менять последующие слои LLM, предположим они получили от сильного steering вектора 7 слоя некоторые возмущения. Это соображение, а также другой способ зашумления дали некоторые скромные результаты. Перспективным решением автор считает исправлять зашумления на всех слоях от 7 до конечного, для того чтобы отловить влияние, скажем так, негативной компоненты steering вектора. Однако это не было проверено.

10. Ограничения экспериментов

1. Concept metric использует тот же SAE feature, что и steering.

Это делает оценку удобной и интерпретируемой, но частично внутренней. В дальнейшем желательно использовать независимый classifier или LLM judge.

2. PPL измеряется той же GPT-2.

Это логично как measure of compatibility с базовой моделью, однако независимая evaluator LM была бы дополнительной проверкой.

3. Небольшой evaluation set.

Используются 6 prompts и 5 seeds. Для более сильной статистики нужен существенно больший benchmark.

4. Training perturbations не совпадают с steering.

Ни Gaussian noise, ни interpolation corruption не являются точной моделью perturbation αv .

5. Pareto improvement локально.

Наиболее успешный результат получен при $\alpha = 24$, но новая модель не доминирует raw steering во всём диапазоне α .

11. Возможные дальнейшие эксперименты

Перспективными являются следующие направления.

1. Обучать denoiser на смеси random isotropic noise и случайных directional perturbations, при этом не используя target steering vector.

2. Добавить явное ограничение на относительную correction norm:

$$\mathcal{L}_{\text{rel}} = \left(\frac{\|\Delta h\|_2}{\|d_{\text{raw}}\|_2 + \varepsilon} \right)^2.$$

3. Использовать hinge:

$$\max \left(0, \frac{\|\Delta h\|_2}{\|d_{\text{raw}}\|_2 + \varepsilon} - c \right)^2.$$

4. Провести более плотный sweep около

$$\alpha = 16 \dots 32,$$

особенно около $\alpha = 24$.

5. Проверить несколько SAE features при одном и том же обученном feature-agnostic denoiser.

6. Добавить независимую semantic metric.

12. Заключение

В работе исследовалась задача улучшения activation steering через обучаемое восстановление скрытых состояний.

Сначала был найден хорошо интерпретируемый SAE feature 17363 на седьмом transformer-блоке GPT-2 Small. Raw steering показал ожидаемый trade-off: при малых и средних α science-концепт усиливается, а при слишком больших α качество генерации разрушается и сам concept исчезает.

Простой same-layer Gaussian MSE denoiser оказался недостаточно устойчив: хотя он способен уменьшать MSE для сильного random noise, его перенос на structured steering perturbation слаб.

Downstream gated repair с LM objective хорошо восстанавливал random-noise validation PPL, но на реальном steering ухудшал полезный regime. Анализ показал, что модель выполняла слишком большую correction и фактически работала как дополнительный residual adapter.

Наиболее успешным оказался improved interpolation denoiser:

$$D_{\theta}(x_t, t) = x_t + (1 - t)\Delta_{\theta}(x_t, t).$$

Он показал уверенное reconstruction improvement во всём диапазоне $t \in [0.5, 0.99]$ и дал строгий локальный Pareto gain при

$$\boxed{\alpha = 24}.$$

Итог:

$C : 7.5621 \rightarrow 8.2392,$

$PPL : 22.2017 \rightarrow 21.4873.$

Главный открытый вопрос — как обучать denoiser на достаточно общем distribution perturbations, чтобы он переносился на неизвестные structured semantic steering directions без явного знания target vector.